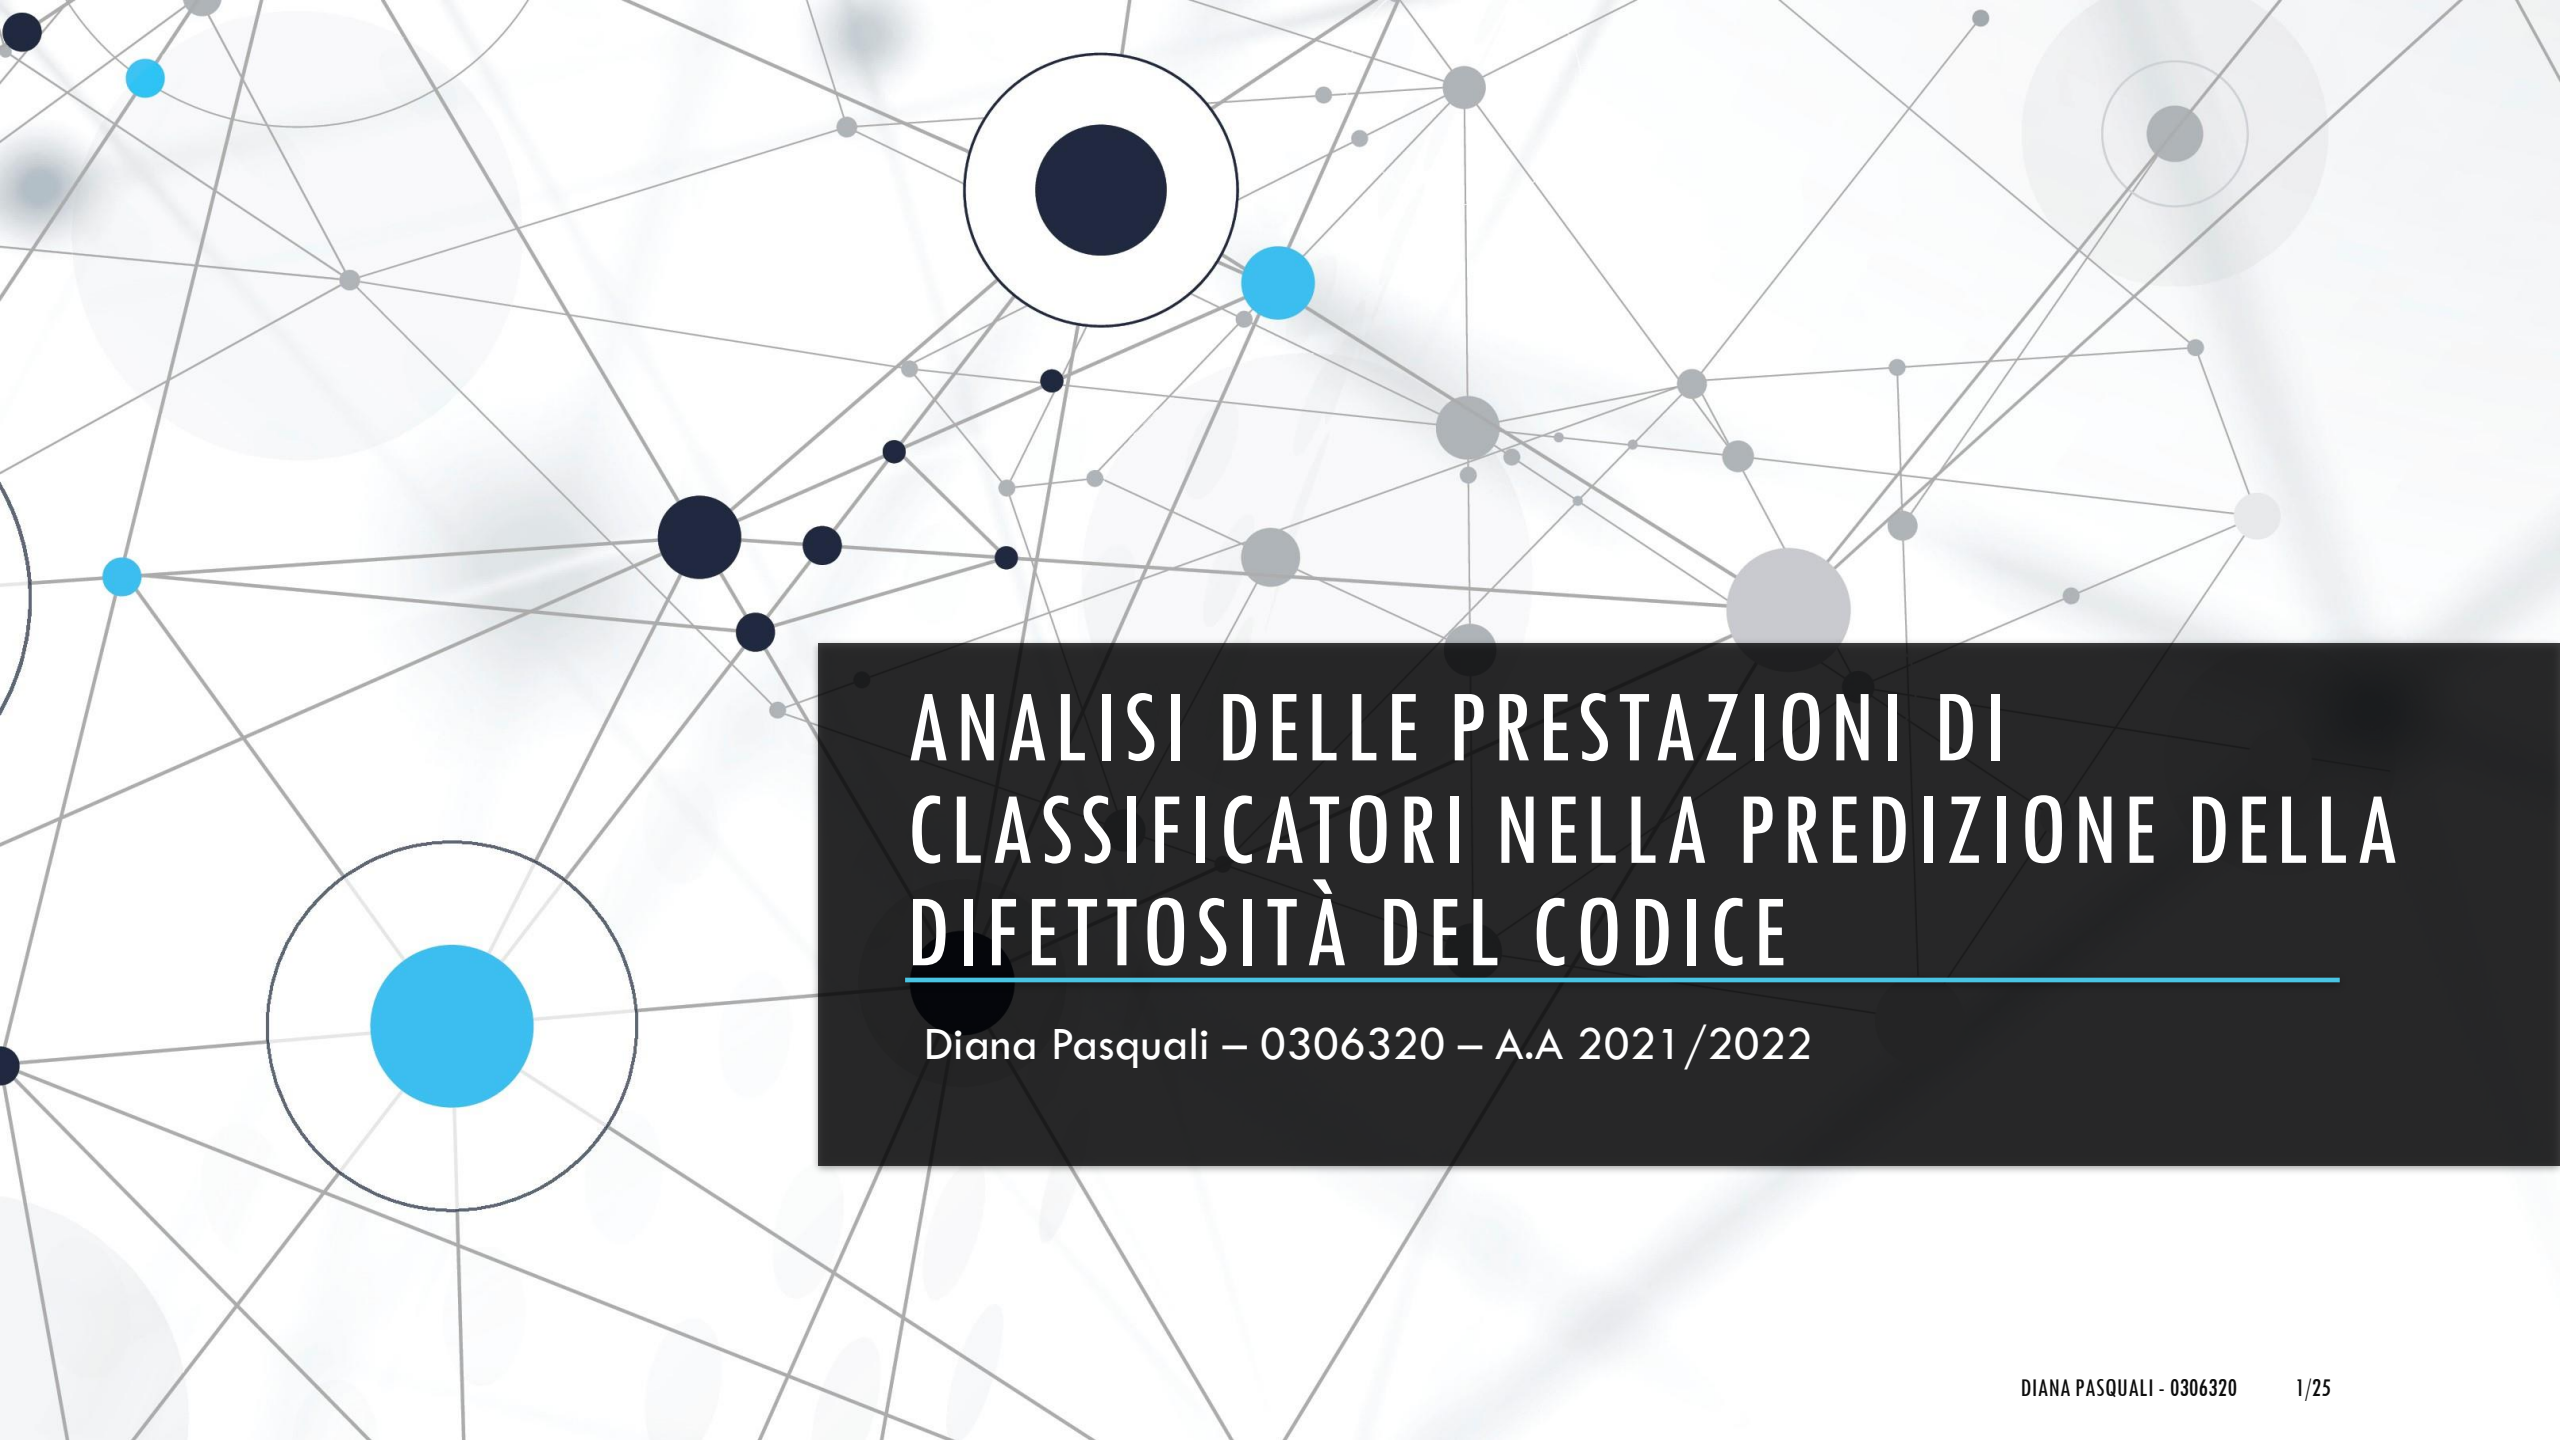

ANALISI DELLE PRESTAZIONI DI CLASSIFICATORI NELLA PREDIZIONE DELLA DIFETTOSITÀ DEL CODICE

Diana Pasquali – 0306320 – A.A 2021/2022

OUTLINE

- Introduzione
- Progettazione
- Metriche considerate
- Risultati
- Discussione dei risultati

INTRODUZIONE

Obiettivo: illustrare l'andamento delle prestazioni di tre classificatori nel predire la difettosità di classi Java, al variare al variare delle tecniche di Balancing applicate.

Obiettivo 2: illustrare l'andamento delle prestazioni dei tre classificatori nel predire la difettosità di classi Java, applicando Feature Selection e valutare la rilevanza delle feature rispetto al modello in esame.

- I classificatori sono addestrati su un dataset che rappresenta la difettosità delle classi Java nei due progetti Apache/BookKeeper e Apache/Syncope.
- I classificatori considerati sono Ibk, NaiveBayes e RandomForest.
- Le tecniche di Balancing considerate sono Oversampling, Undersampling e SMOTE.
- La tecnica di Feature Selection valutata è BestFirst (Filtro) con Backward Search.

PROGETTAZIONE

- Prima di procedere all'addestramento dei classificatori, è necessario costruire il dataset da utilizzare.
- Una volta costruito il dataset, sono stati rimossi i dati relativi all'ultimo 50% delle release in modo da ridurre l'effetto di Snoring.
- Il dataset costituito da differenti colonne che specificano:
  - Una **versione**
  - Un **file** java
  - 16 **metriche** (correlate alla presenza o meno di bug nel file e nella versione considerati)
  - Un'**etichetta** "Yes/No" per specificate se il file è risultato o meno difettoso all'interno della versione.

PROGETTAZIONE - METRICHE

- Le principali metriche considerate sono le seguenti:

Size: lo storico dimensione del file in termini di LOC (cross-release).

- Un valore alto di linee di codice, provocano un rischio maggiore di avere bug.

LOC_Touched: la somma delle LOC aggiunte e rimosse nell'arco delle revisioni sulla singola versione (intra-release).

- Un numero alto indica che sono cambiate molte LOC del file nella versione e allora c'è più possibilità di generare bugs.

NFix: il numero di revisioni al file che risolvono delle issues di Jira nella singola versione (intra-release).

- Un numero alto di commit che cercano di risolvere issues, potrebbe significare una difficile risoluzione dei problemi nel codice oppure una propensione del file ad essere difettoso.

PROGETTAZIONE - METRICHE

NR: il numero di revisioni al file nella singola versione (intra-release).

- Maggiori sono i commit al file, e maggiori sono le possibilità di introdurre bug.

NAuth: il numero di autori totali che hanno collaborato al file nella versione (intra-release).

- Con un valore elevato, aumentano le probabilità di generare difetti nel codice a causa di incomprensioni e delle differenti intenzioni tra i collaboratori.

LOC_Added: il numero di LOC aggiunte (intra-release).

- Simile alla Size. Più LOC sono aggiunte al file e maggiore è la possibilità di avere introdotto bug.

Churn: è la somma sulle revisioni di LOC added – deleted per la singola versione (intra-release).

- Un valore elevato rappresenta il numero di linee di LOC effettivo che potrebbe contribuire ad introdurre un bug nella classe.

PROGETTAZIONE - METRICHE

ChgSetSize: è il numero di files che sono stati modificati da commit insieme al file specificato (intra-release).

- Più sono i file modificati insieme in un certo commit e più sarà difficile identificare la natura dei bug eventualmente generato.

Age: è l'età della classe calcolata in termini di settimane (cross-release).

- Una classe con valore di età maggiore risulta più stabile in termini di difettosità e meno propensa ad avere bug.

WeightedAge: è l'età della classe pesata sul numero di LOC_touched (cross-release).

- Si considerano contemporaneamente l'età della classe e il numero totali di LOC aggiunte o rimosse.

Sono anche state considerate le seguenti: **MAX_LOC_Added, AVG_LOC_Added; MAX_Churn, AVG_Churn; MAX_ChgSetSize AVG_ChgSetSize.**

PROGETTAZIONE - MISURAZIONI

- Le metriche relative al codice dei progetti sono state raccolte usando il programma **Isw2-ProjectBugsAnalysis.**
- Usando il file di configurazione è possibile specificare il progetto e la percentuale delle release da considerare una volta prodotto il dataset finale.
- Per recuperare le informazioni sul progetto sono stati usati:
  - **Git:** per ottenere le informazioni relative ai commit.
  - **Jira:** per ottenere le informazioni relative ai tickets e alle versioni.
- Le LOC aggiunte ed eliminate per ogni file vengono raccolte ripercorrendo la storia dei commit ed infine tramite le funzionalità di FeatureCalculator è possibile calcolare le metriche finali.
- Tutti i risultati prodotti sono raccolti in istanze di tipo Record identificate da versione e nome del file e le cui informazioni complessive vengono infine scritte su un file CSV.

PROGETTAZIONE – BUGGYNESS

- La **BUGGYNESS** è una metrica che specifica se una classe è difettosa o meno in una certa release.
- Per capire se una classe è difettosa o meno in una release è stato applicato il seguente algoritmo:
  1. Si raccolgono tutti i ticket relativi al progetto in esame che riguardano bug, sfruttando l'API di **Jira**.
  2. Per ogni ticket si recuperano i valori di AV.
  3. Si identificano i commit del progetto che fanno riferimento ad almeno uno di questi ticket.
  4. Si assegnano ad ogni classe Java modificata dal commit che fa rifermento ad un certo ticket i valori di AV dello stesso. Si stima perciò che la classe sarà difettosa per tutte le AV.
- Per ogni ticket, si controlla che le AV siano consistenti con le FV e pertanto vengono scartati i ticket per cui FV sia precedente a tutte le AV.
- Se per il ticket non sono specificate AV allora viene applicato il metodo **Proportion**.

PROGETTAZIONE – PROPORTION

- Ogni bug ha un ciclo di vita con una specifica **proporzione** definita da OV, FV, IV ed in particolare è possibile calcolarla tramite la formula:

$$p = \frac{FV - IV}{OV - IV}$$

- Per ogni ticket, il valore di p è stato calcolato applicando la tecnica di proportion **MovingWindow**, ossia considerando la media dei valori di p per l'1% dei ticket precedenti.
- In caso di AV mancanti o inconsistenti per un certo ticket, è possibile calcolare il valore di IV utilizzando il valore di p di quello stesso ticket.
- In caso non ci siano ticket precedenti, allora non viene assegnato un valore di default a p , ma si applica il metodo di proportion **ColdStart**, ottenendo il valore medio dei valori medi di p per altri 16 progetti Apache.

PROGETTAZIONE - EVALUATION

- Per valutare la difettosità del progetto nel corso delle release, è stata utilizzata la tecnica di validazione **WalkForward**, dal momento che i dati sono strettamente legati ad aspetti temporali.
  - Ad ogni iterazione, il dataset iniziale viene diviso in training set e testing set, considerando una release come testing e tutte le precedenti vengono incluse nel training.
- Per applicare i classificatori e le varie tecniche di FeatureSelection, Balancing e SensitiveClassification è stata utilizzata l'API messa a disposizione da **Weka**.
- E' stata implementata inoltre una classe Analyzer che permette di creare una pipeline di tecniche da valutare successivamente usando Weka.
- L'effettiva valutazione della pipeline di tecniche applicate, avviene nel metodo **evaluation()** della classe Pipeline.
  - Il metodo istanzia un oggetto Evaluation di Weka che esegue la valutazione del modello costruito.

DISCUSSIONE RISULTATI

- Per analizzare le metriche ottenute dalla fase di valutazione è stato utilizzato il programma **Jmp** per realizzare dei grafici che sintetizzassero l'evoluzione di tali metriche.
- Per valutare la rilevanza delle features è stata utilizzata la GUI di Weka.
- Per mitigare l'effetto di **Snoring** è stato scartato il 50% delle versioni più recenti dal dataset, prima di essere valutato dal classificatore.
  - E' più facile che ci siano falsi negativi nelle ultime release. Perciò per evitare di ottenere risultati falsati, sono state valutate solo le prime release di ogni progetto.
- Le per ogni classificatore e tecnica di F.Selection e Balancing si sono analizzate:
  - ✓ **AUC**
  - ✓ **Kappa**
  - ✓ **Precision**
  - ✓ **Recall**

DISCUSSIONE RISULTATI - FEATURES

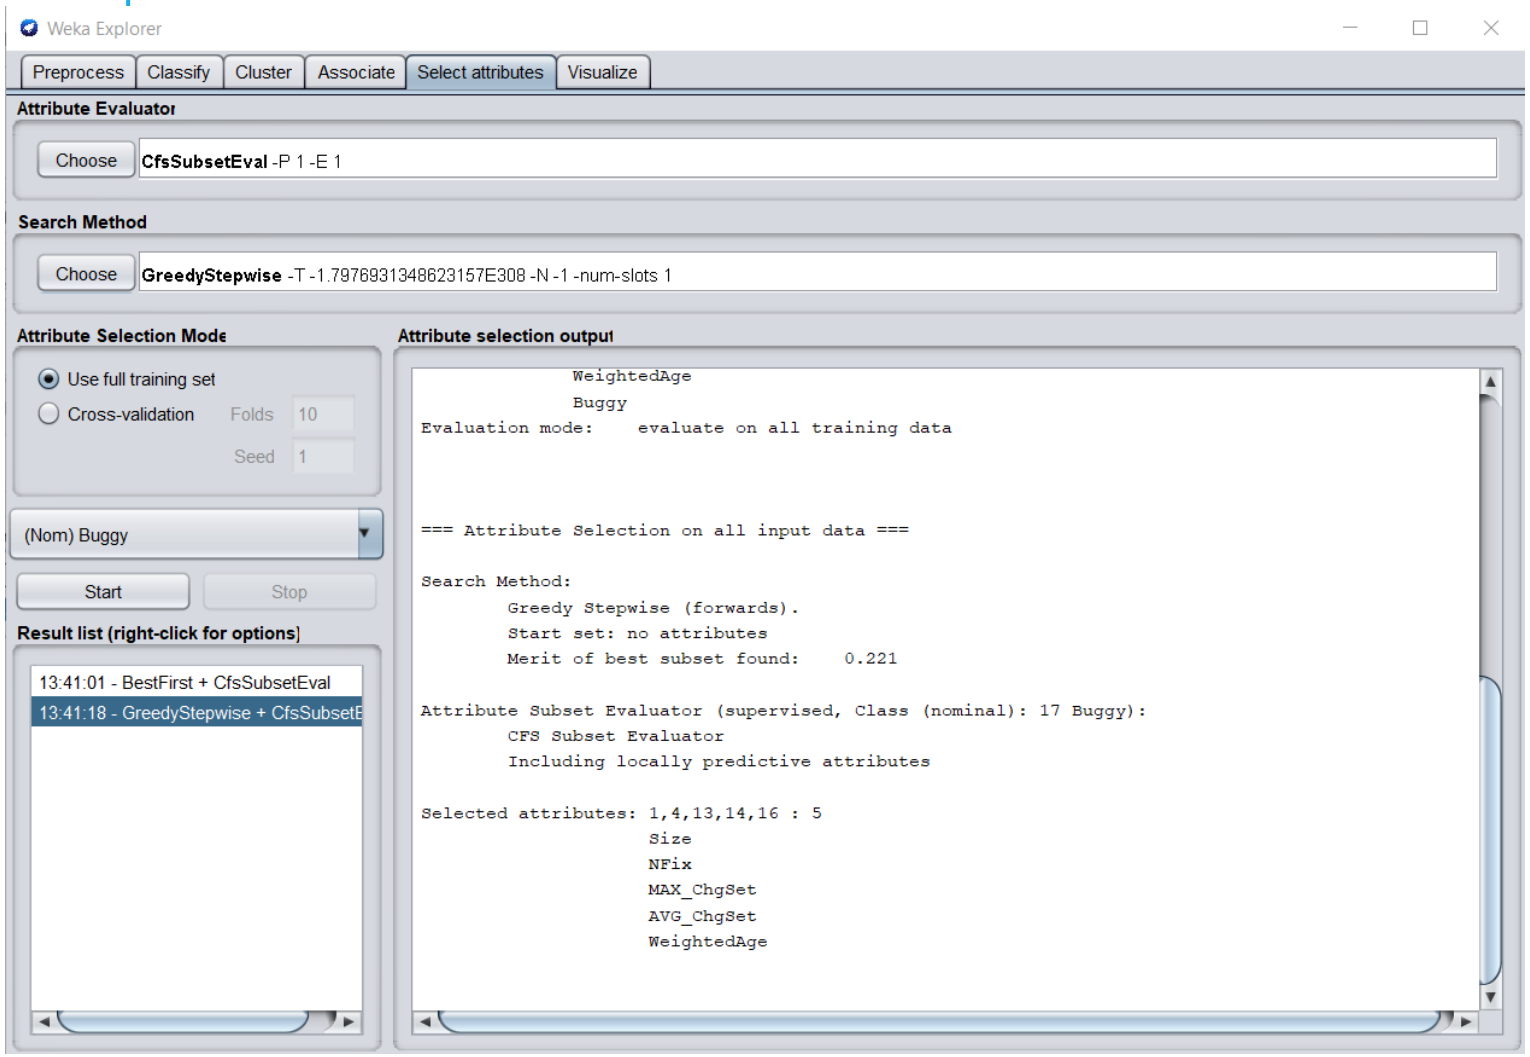

- Applicando la Feature Selection, è possibile identificare quali sono gli attributi che hanno una rilevanza maggiore rispetto alla variabile di classificazione (Buggy).
- Sia applicando BestFirst, sia applicando GreedyStepwise, si ottiene che le metriche più rilevanti sulla base del dataset fornito sono:
  - ✓ Size
  - ✓ NFix
  - ✓ MAX_ChgSet
  - ✓ AVG_ChgSet
  - ✓ WeightedAge

DISCUSSIONE RISULTATI – AUC

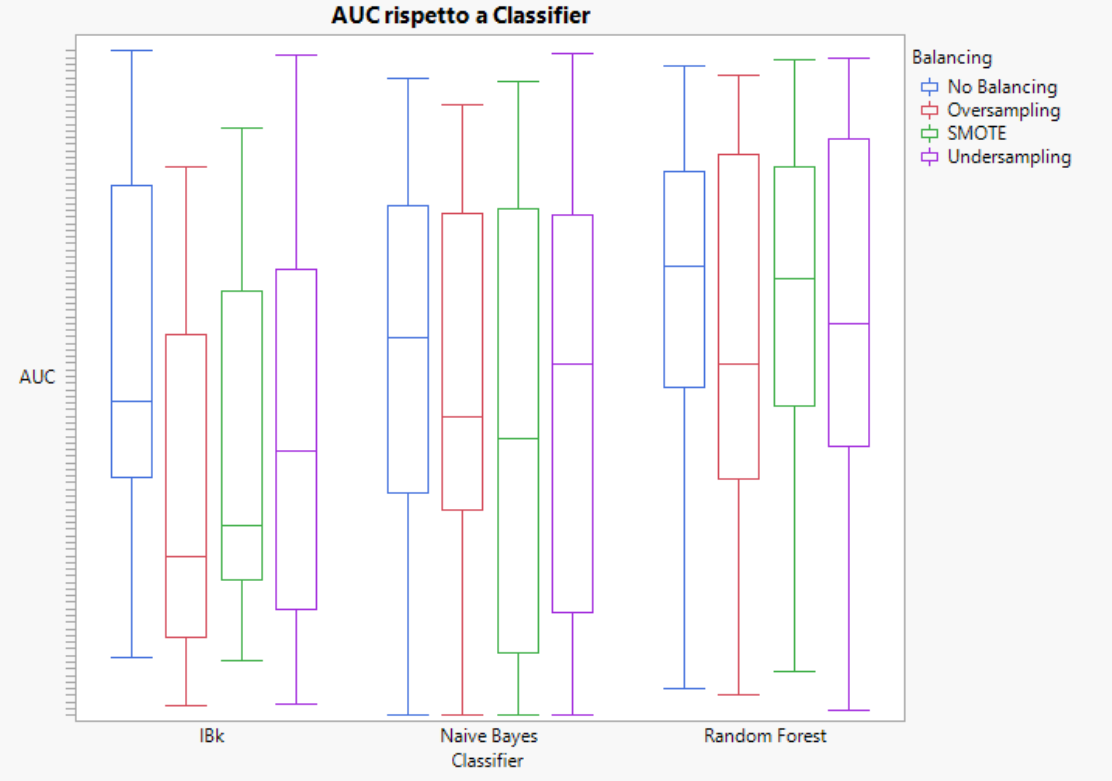

- Si considerano i dati del progetto BookKeeper.
- La tecnica **Undersampling** è quella che peggiora di meno le prestazioni dei classificatori IBk e NaiveBayes.
- La tecnica **Oversampling** invece, peggiora notevolmente le prestazioni di tutti i classificatori rispetto a quando non vengono applicate tecniche di bilanciamento.
- La tecnica **SMOTE** peggiora le prestazioni di tutti i classificatori, maggiormente in IBk e NaiveBayes.

DISCUSSIONE RISULTATI – KAPPA

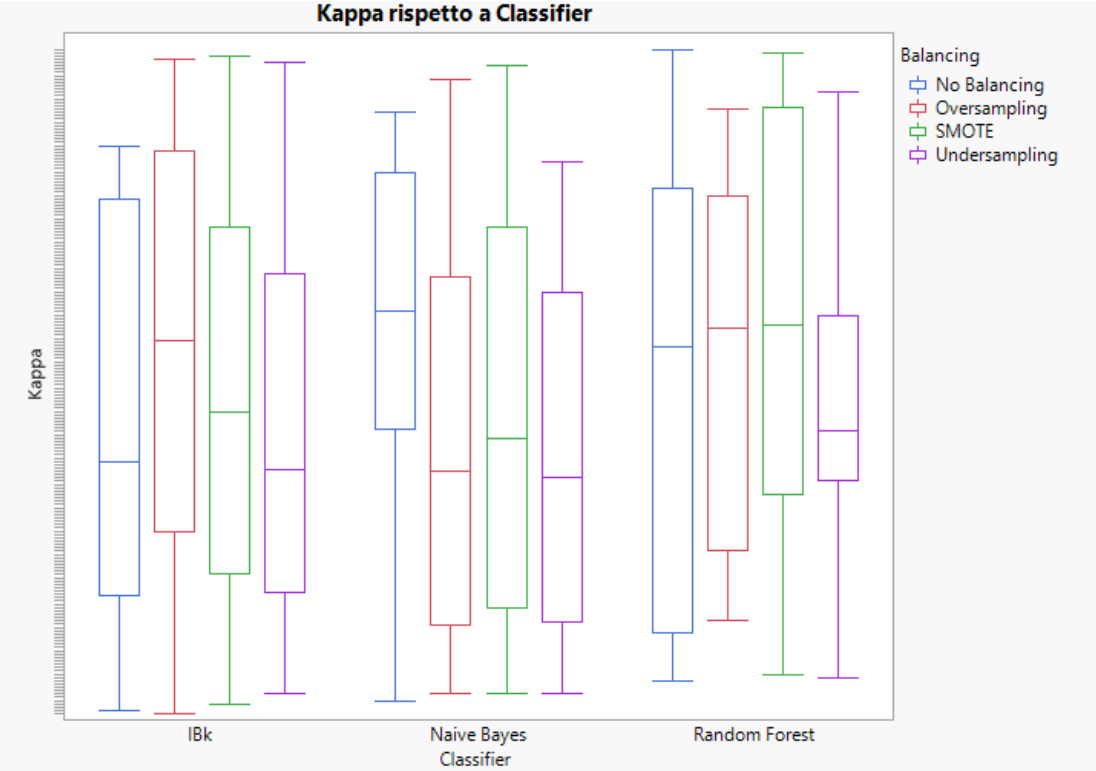

- Si considerano i dati del progetto BookKeeper.
- Le prestazioni di **NaiveBayes** peggiorano parecchio rispetto ad un classificatore "dummy", applicando qualsiasi tecnica di bilanciamento sul dataset in input.
- Le prestazioni di **RandomForest** invece, migliorano leggermente applicando il bilanciamento con SMOTE e peggiorano applicando Undersampling.
- Nel caso di **IBk**, applicare Oversampling migliora parecchio le prestazioni, mentre Undersampling sembra influire di meno.

DISCUSSIONE RISULTATI – PRECISION

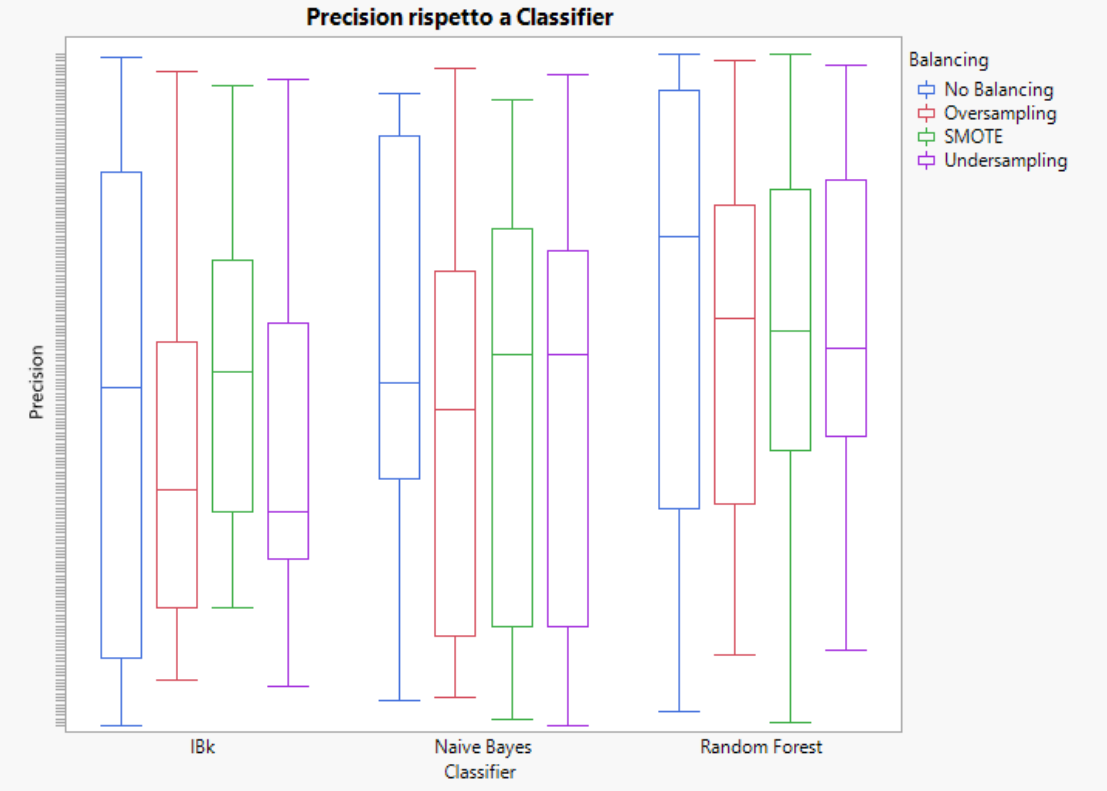

- Si considerano i dati del progetto BookKeeper.
- SMOTE e Undersampling aumentano leggermente la Precision nel caso di NaiveBayes.
- La Precision peggiora notevolmente applicando **Undersampling** ai classificatori RandomForest e IBk.
  - Il maggior peggioramento si ha nel caso di IBk
- Il bilanciamento ha in generale un impatto minore sulla Precision valutata con NaiveBayes rispetto agli altri classificatori.
- SMOTE aumenta leggermente la Precision nel caso di IBk.

DISCUSSIONE RISULTATI – RECALL

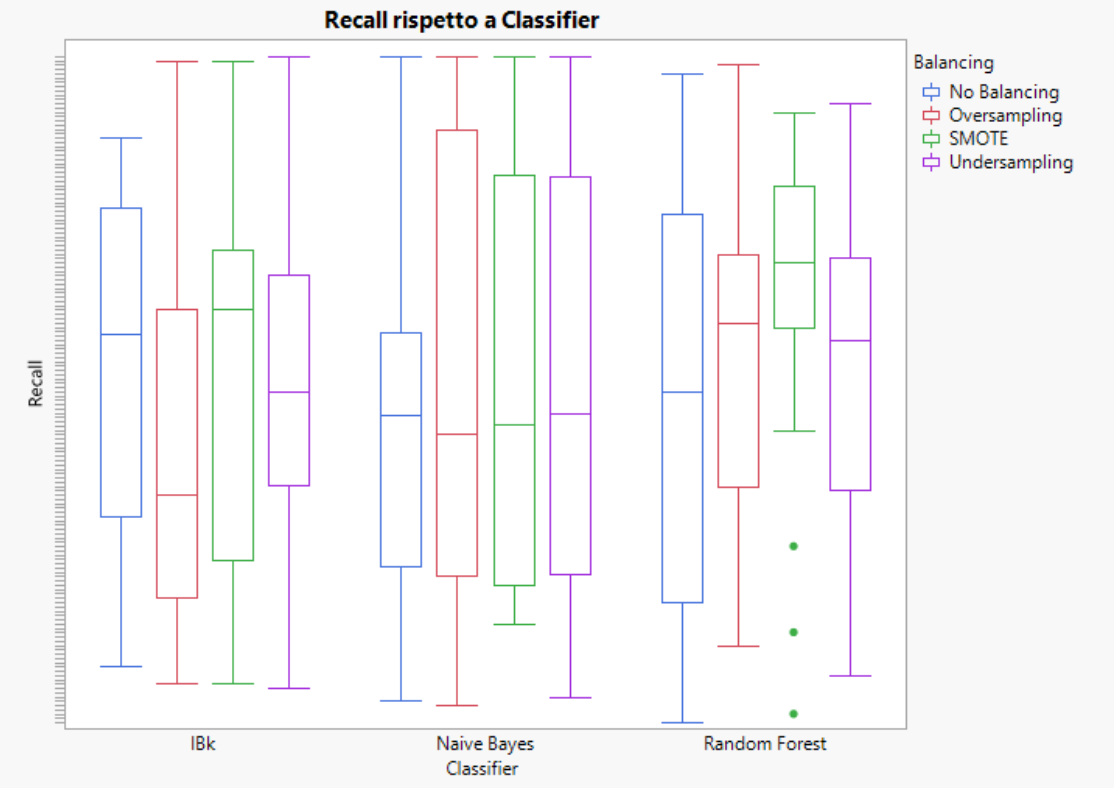

- Si considerano i dati del progetto BookKeeper.
- Nel caso di **RandomForest,** tutte e tre le tecniche aumentano il numero di positivi individuati e quindi la Recall.
  - Non sono hanno valori mediani più alti, ma anche la variabilità della distribuzione è minore.
- Nel caso di IBk e RandomForest, si ottengono più positivi individuati applicando **SMOTE**, sebbene la sua influenza sia più evidente per il secondo.
- In IBk applicare Oversampling o Undersampling riduce il numero di positivi individuati.

DISCUSSIONE RISULTATI – AUC

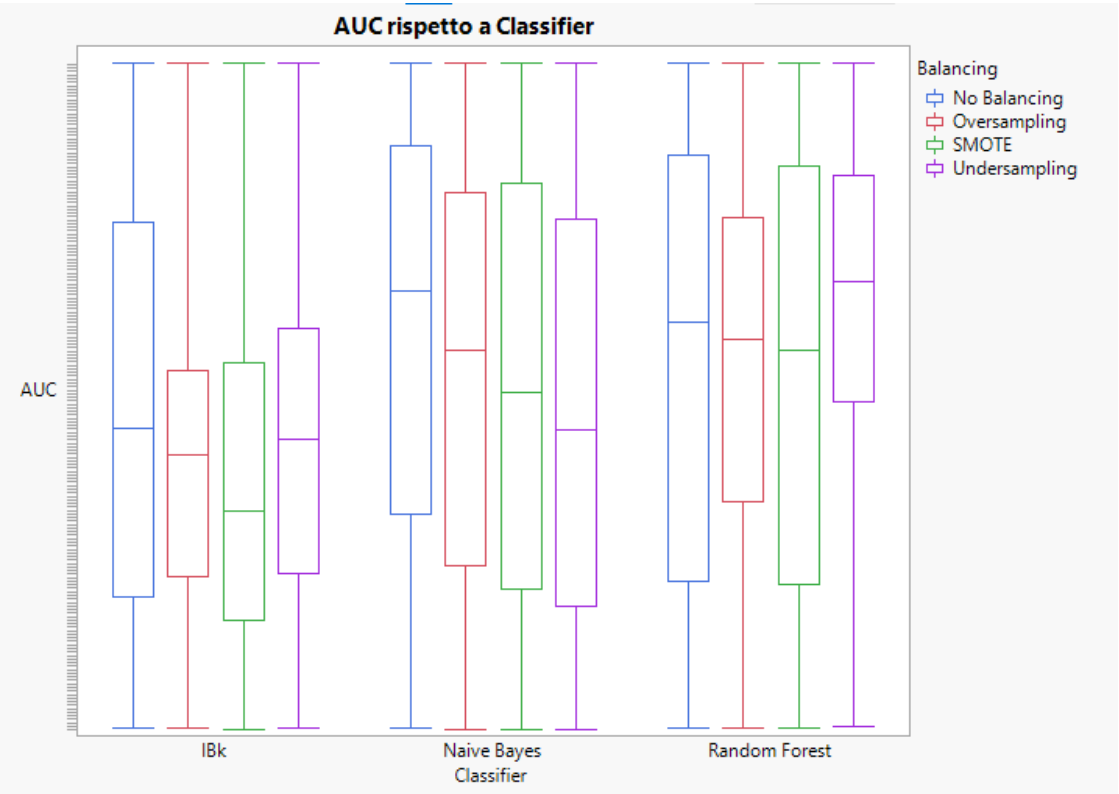

- Si considerano i dati del progetto Syncope.
- Sia per **IBk** che per **NaiveBayes**, applicare tecniche di bilanciamento peggiora in tutti i casi le prestazioni.
- Invece per quanto riguarda **RandomForest** si ottiene un leggero peggioramento del valore di AUC con Oversampling e SMOTE, mentre si ottiene un miglioramento applicando Undersampling.
- Il peggioramento maggiore si ottiene con NaiveBayes applicando Undersampling.

DISCUSSIONE RISULTATI – KAPPA

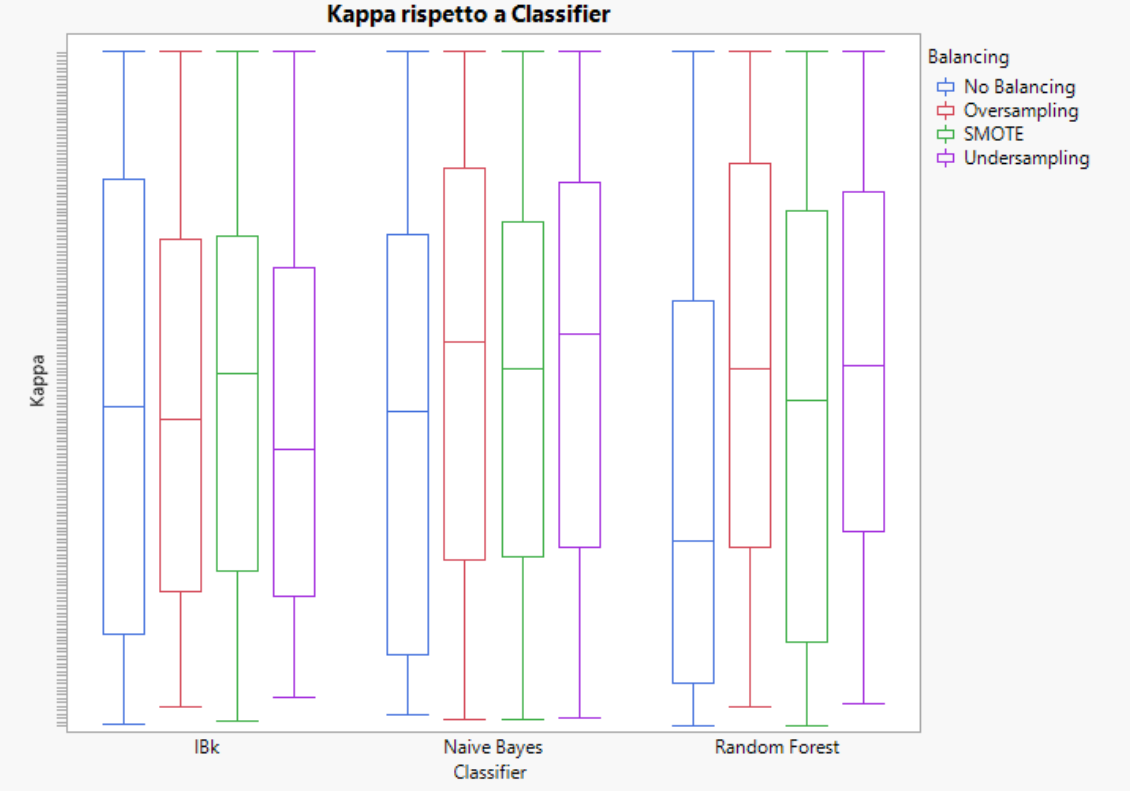

- Si considerano i dati del progetto Syncope.
- In questo caso applicando le tre tecniche di bilanciamento del dataset si ottengono aumenti delle prestazioni dei tre classificatori rispetto al classificatore "dummy".
  - In maniera inferiore per IBk.
- Per **NaiveBayes** e **RandomForest,** tutte e tre le tecniche di bilanciamento migliorano notevolmente .
- Per **IBk** l'unico miglioramento si ottiene applicando SMOTE.

DISCUSSIONE RISULTATI – PRECISION

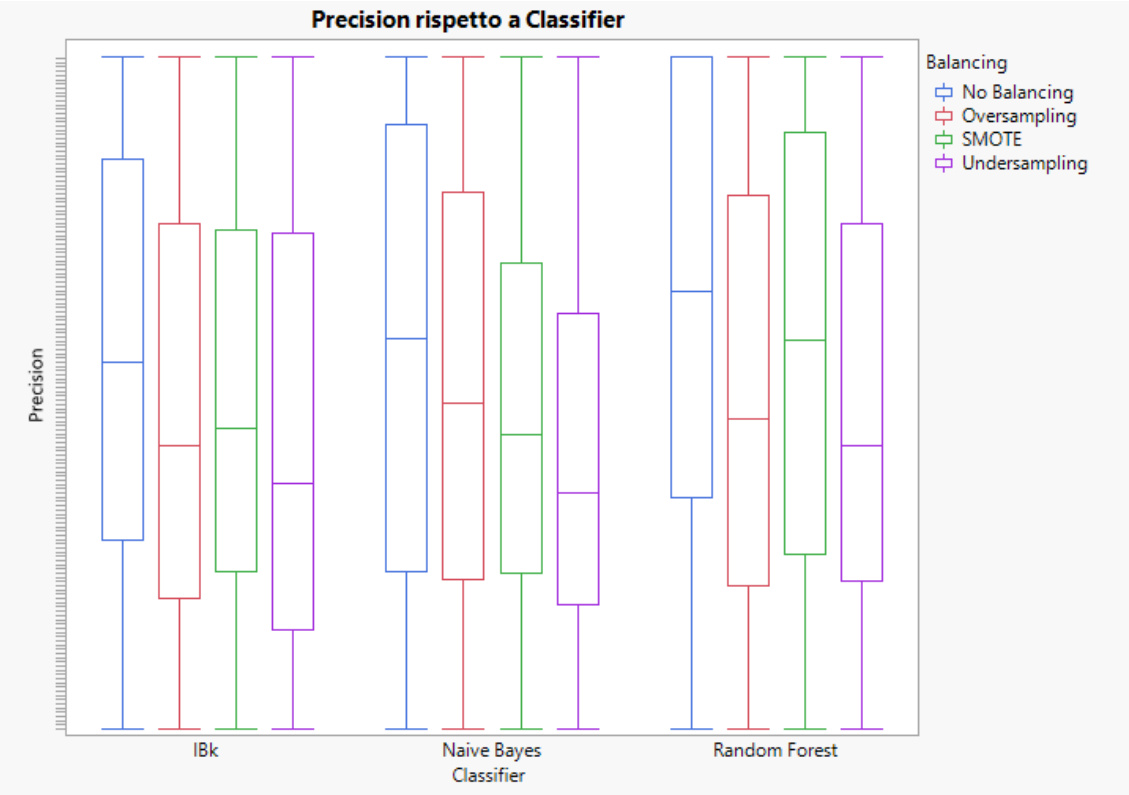

- Si considerino i dati del progetto Syncope.
- In questo caso il valore di Precision diminuisce applicando qualsiasi tecnica di bilanciamento del dataset per tutti i classificatori considerati.
- La tecnica che provoca il peggioramento maggiore del valore della Precision è **Undersampling** per tutti e tre i classificatori.
- La tecnica con la Precision maggiore invece è **SMOTE** per IBk e RandomForest; **Oversampling** per NaiveBayes.

DISCUSSIONE RISULTATI – RECALL

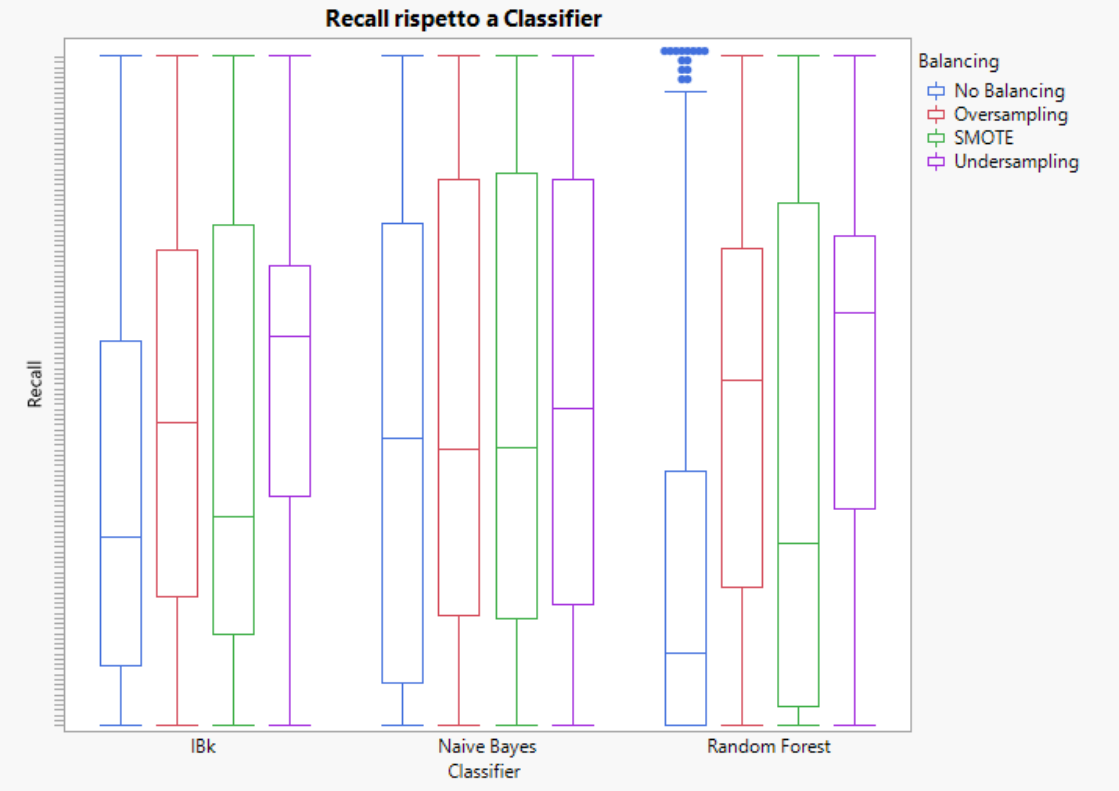

- Si considerano i dati del progetto Syncope.
- Sia per **RandomForest** che per **IBk**, applicare tecniche di bilanciamento aumenta notevolmente il valore di Recall.
- Per **NaiveBayes** invece applicare qualsiasi tecnica di bilanciamento, tende a non influire più di tanto sul valore di Recall.
- Per quanto riguarda la Recall, le tecniche di Undersampling e Oversampling sembrano comportarsi generalmente meglio rispetto a SMOTE, per tutti e tre i classificatori.

CONCLUSIONI – FEATURE SELECTION

- Tra le 16 feature calcolate nel dataset dato in input al modello, solamente **5** sono risultate rilevanti al fine di predire la difettosità delle classi.
  - E' interessante notare come sia stata selezionata la **WeightedAge**, rimuovendo invece gli attributi di LOC_Touched e Age. Infatti, WeightedAge include al suo interno informazioni relative ad entrambe le metriche, pertanto risulta maggiormente significativa.
- In alcuni casi applicare la selezione delle feature migliora abbastanza le prestazioni.
  - Applicando BestFirst sul dataset di Syncope, si ottengono miglioramenti per NaiveBayes e per IBk.
- Il classificatore che migliora sempre applicando BestFirst per entrambi i dataset è NaiveBayes. Questo potrebbe essere dovuto al fatto che NaiveBayes assume che gli attributi del dataset siano il più possibile scorrelati tra loro.

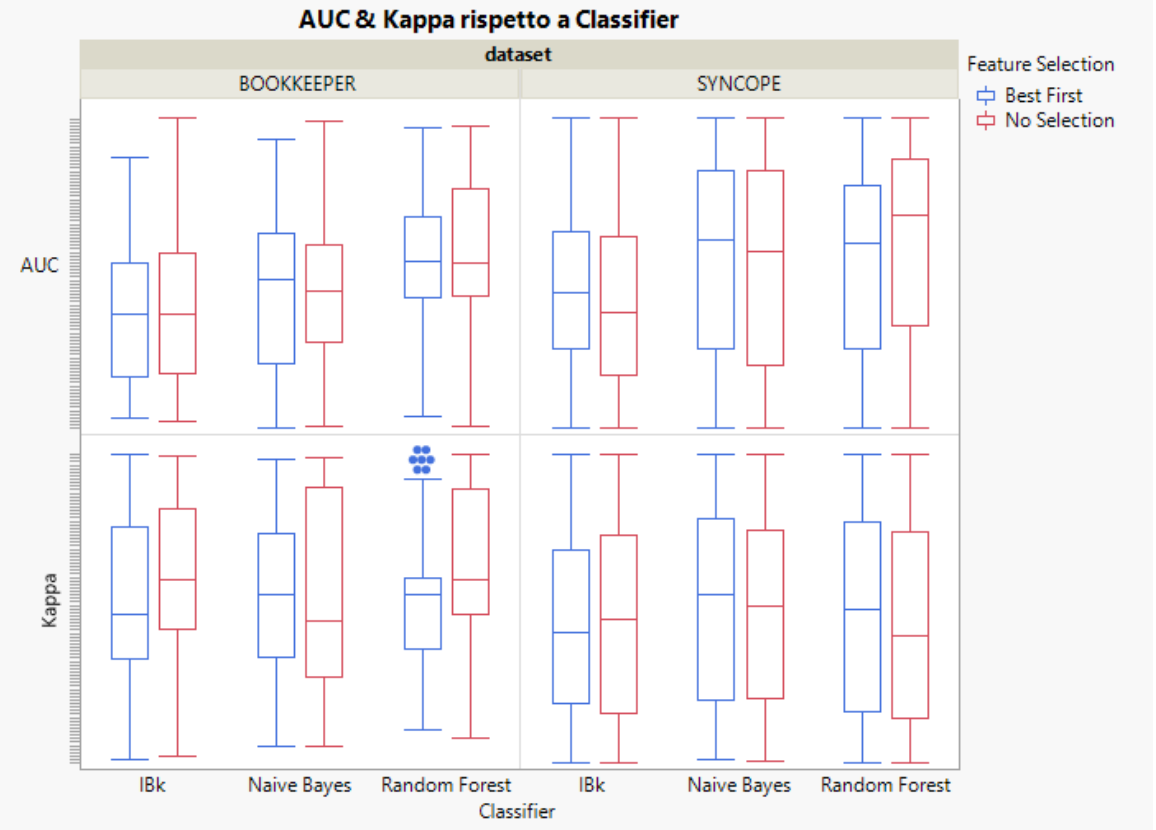

CONCLUSIONI – BILANCIAMENTO

- Tra le tecniche di bilanciamento, non ce n'è una che è nettamente migliore delle altre, ma dipende intrinsecamente dal dataset di partenza e dal classificatore considerato.
- Su Syncope, si ottiene un numero maggiore di positivi individuati applicando **Undersampling**, mentre su BookKeeper si ottengono più positivi applicando **SMOTE**.
- Confrontando i valori di Recall senza applicare le tecniche di bilanciamento è evidente come essa sia maggiore sul dataset di BookKeeper, poiché esso è meno sbilanciato.
  - Buggy BookKeeper: 38%
  - Buggy Syncope: 5%
- Per questo motivo, il bilanciamento ha un impatto mediamente maggiore su Syncope rispetto a BookKeeper a prescindere dal classificatore.
- Il classificatore su cui mediamente non ha impatto il bilanciamento è **NaiveBayes**. Questo può essere dovuto al fatto che esso è un classificatore ad approccio generativo e dunque si presuppone che i dati siano generati seguendo lo stesso processo di generazione.

CONCLUSIONI - CLASSIFICATORI

- Tra i diversi classificatori, non ce n'è uno che ha performance migliori degli altri, ma anche in questo caso i risultati variano in base al dataset iniziale e alle varie tecniche applicate.
- Il classificatore che in generale ha le performance più basse è proprio **NaiveBayes**, lo stesso classificatore su cui hanno meno impatto le tecniche di bilanciamento, nonostante la sostanziale differenza di bilanciamento dei dataset iniziali.
- Performance leggermente migliori si ottengono con RandomForest, il quale a differenza degli altri classificatori rientra nella categoria dei **bagging classifiers**.
- Dal momento che è stato usato WalkForward come tecnica di validazione, è possibile che ci siano iterazioni particolarmente sfortunate che pesano negativamente sulle prestazioni. Generando molteplici alberi di decisione su cui mediare il risultato finale delle prestazioni, RandomForest riesce a mitigare i risultati negativi aumentando le performance generali.

GRAZIE PER L'ATTENZIONE!

Link alla repository Github:

Isw2-ProjectBugsDataset:Diana0422/Isw2-ProjectBugsDataset (github.com)

Isw2-ProjectBugsAnalysis: Diana0422/Isw2-ProjectBugsAnalysis (github.com)

Link a SonarCloud:

Isw2-ProjectBugsDataset: Isw2-ProjectBugsDataset - Diana0422 (sonarcloud.io)

Isw2-ProjectBugsAnalysis: Isw2-ProjectBugsAnalysis - Diana0422 (sonarcloud.io)